Ladění výkonu PostgreSQL

Prague PostgreSQL Developer Day 2015 / 11.2.2015

Tomáš Vondra

tomas.vondra@2ndquadrant.com / tomas@pgaddict.com

Agenda

- shared_buffers
- (maintenance_)work_mem
- effective_cache_size
- effective_io_concurrency
- max_connections
- unix vs. TCP/IP socket
- temp_file_limit
- bgwriter (delay / ...)
- wal_level
- wal_log_hints
- synchronous_commit
- commit_delay / commit_siblings
- checkpoint_segments (timeout / completion_target)
- default_statistics_target
- autovacuum options

Zdroje

PostgreSQL 9.0 High Performance (Gregory Smith)

- vyčerpávající přehled problematiky
- víceméně základ tohoto workshopu

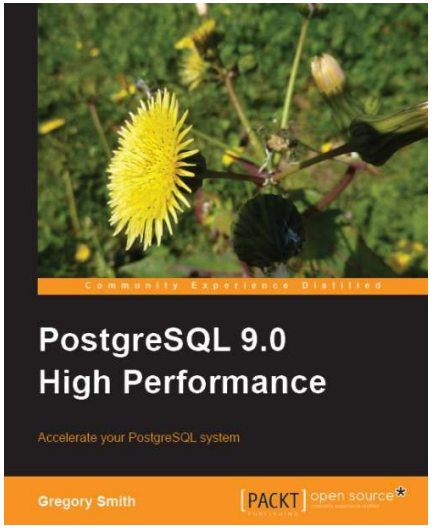

PostgreSQL 9 High Availability (Shaun M. Tomas)

- ne přímo o tuningu, ale HA je “příbuzné téma”
- hardware planning, performance triage, …

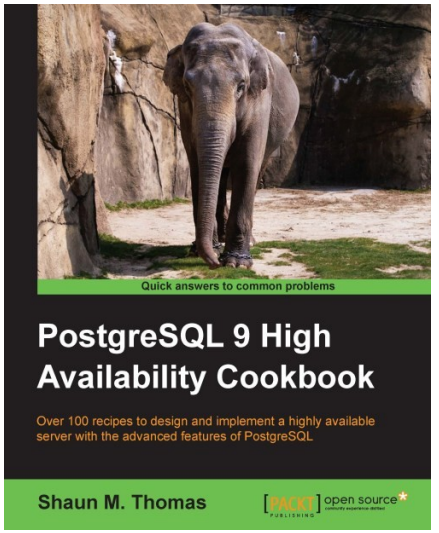

What Every Programmer Should Know About Memory

- Ulrich Drepper, Red Hat
- http://www.akkadia.org/drepper/cpumemory.pdf
- hutné low-level pojednání o CPU a RAM

Righting Your Writes (Greg Smith)

- http://2ndquadrant.com/media/pdfs/talks/RightingWrites.pdf

PostgreSQL Wiki

- https://wiki.postgresql.org/wiki/Tuning_Your_PostgreSQL_Server

#1

Každý systém má bottleneck.

#2

Někdy je nejlepší tuning upgrade.

#3


I HAVE NO IDEA
WHAT I'M DOING
HAVE YOU TRIED INCREASING
SHARED_BUFFERS?
imgflip.com

PostgreSQL architektura

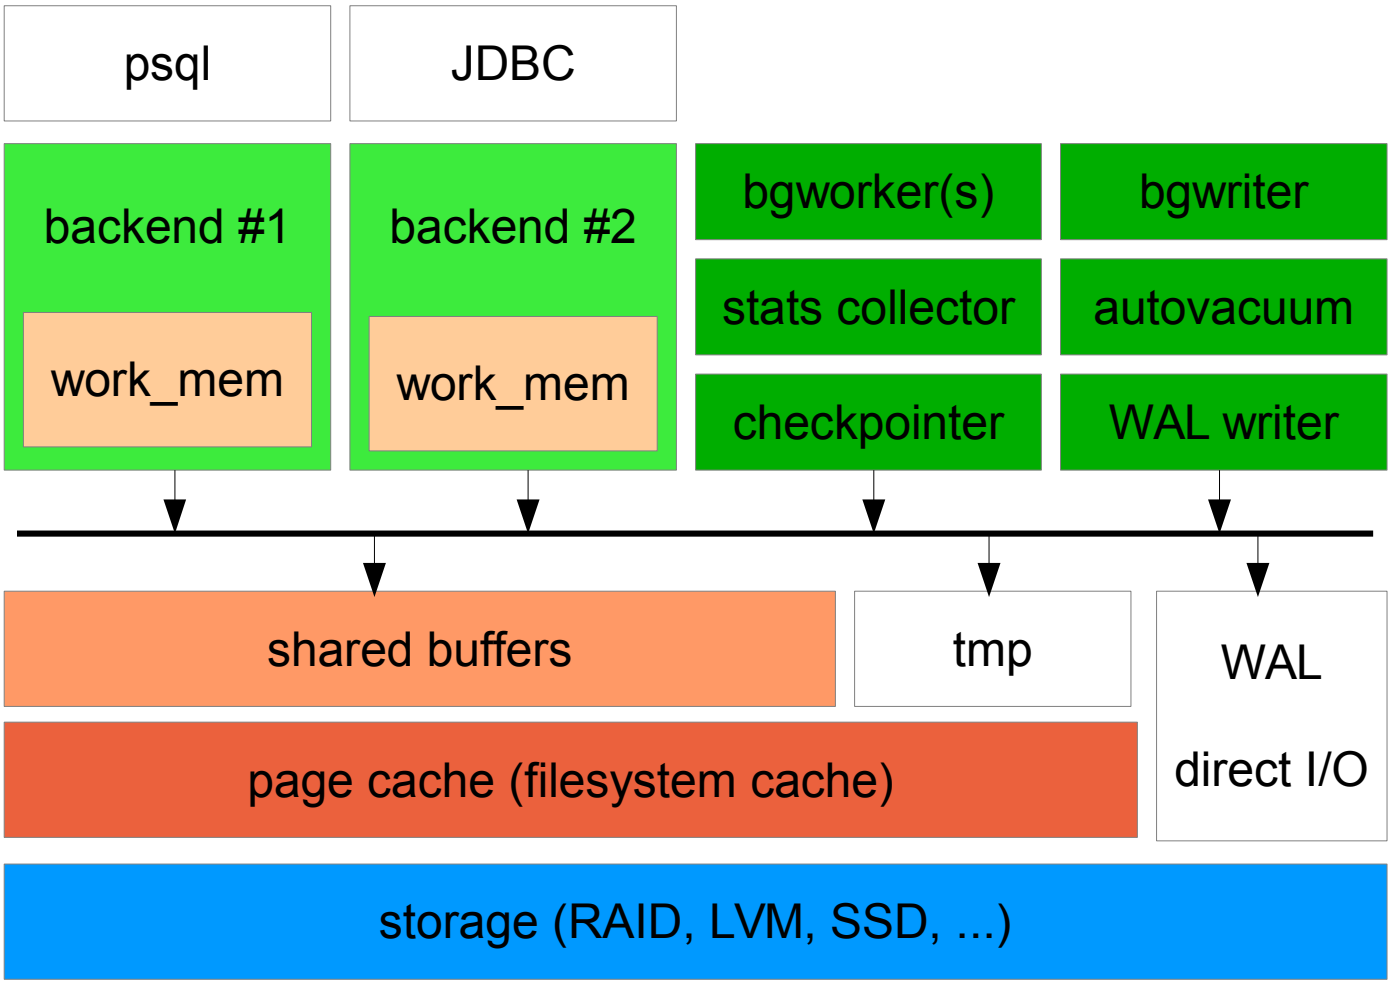

PostgreSQL architektura

```
$ ps ax | grep postg
 4963 pts/2    S      0:00 /home/tomas/pg/bin/postgres -D /var/pgsql/data
 4965 ?        Ss     0:00 postgres: checkpointer process
 4966 ?        Ss     0:00 postgres: writer process
 4967 ?        Ss     0:00 postgres: wal writer process
 4968 ?        Ss     0:00 postgres: autovacuum launcher process
 4969 ?        Ss     0:00 postgres: stats collector process
```

pgbench

inicializace

```
$ createdb bench
$ pgbench -i -s 1000 bench
```

exekuce (read-write)

```
$ pgbench -c 16 -T 600 bench
```

exekuce (read-only)

```
$ pgbench -S -c 16 -j 4 -T 600 bench
```

exekuce (vlastní skript)

```
$ pgbench -c 16 -j 4 -f skript.sql -T 600 bench
```

pgbench (init)

```
$ createdb test
$ time pgbench -h localhost -i -s 1000 test
NOTICE:  table "pgbench_history" does not exist, skipping
NOTICE:  table "pgbench_tellers" does not exist, skipping
NOTICE:  table "pgbench_accounts" does not exist, skipping
NOTICE:  table "pgbench_branches" does not exist, skipping
creating tables...
100000 of 100000000 tuples (0%) done (elapsed 0.02 s, remaining 16.21 s).
200000 of 100000000 tuples (0%) done (elapsed 0.03 s, remaining 16.35 s).
...
50900000 of 100000000 tuples (50%) done (elapsed 47.89 s, remaining 46.20 s).
...
99900000 of 100000000 tuples (99%) done (elapsed 99.26 s, remaining 0.10 s).
100000000 of 100000000 tuples (100%) done (elapsed 99.41 s, remaining 0.00 s).
vacuum...
set primary keys...
done.

real    6m43.962s
user    0m18.254s
sys     0m0.767s
```

pgbench (test)

```
$ pgbench -j4 -c4 -T 600 test
starting vacuum...end.
transaction type: TPC-B (sort of)
scaling factor: 1000
query mode: simple
number of clients: 4
number of threads: 4
duration: 600 s
number of transactions actually processed: 702704
tps = 1171.160579 (including connections establishing)
tps = 1171.163316 (excluding connections establishing)
```

pgbench (read-only test)

```
$ pgbench -S -j4 -c4 -T 600 test
starting vacuum...end.
transaction type: SELECT only
scaling factor: 1000
query mode: simple
number of clients: 4
number of threads: 4
duration: 600 s
number of transactions actually processed: 2136869
tps = 3561.435957 (including connections establishing)
tps = 3561.445152 (excluding connections establishing)
```

shared_buffers

- paměť vyhrazená pro databázi
- prostor sdílený všemi databázovými procesy
- cache “bloků” z datových souborů (8kB)
  - částečně duplikuje page cache (double buffering)
- bloky se dostávají do cache když …
  - backend potřebuje data (query, autovacuum, backup ...)
- bloky se dostávají z cache když
  - nedostatek místa v cache (LRU)
  - průběžně (background writer)
  - checkpoint
- bloky mohou být čisté nebo změněné (“dirty”)

shared_buffers

- default 32MB, resp. 128MB (od 9.3)
  - 32MB je zoufalý default, motivovaný limity kernelu (SHMALL)
  - 9.3 alokuje sdílenou paměť jinak, nemá problém s limity
  - 128MB lepší, ale stále dost konzervativní (kvůli malým systémům)
- co je optimální hodnota ...
  - Proč si DB nezjistí dostupnou RAM a nenastaví “správnou” hodnotu?
  - závisí na workloadu (jak aplikace používá DB)
  - závisí objemu dat (aktivní části)
  - větší cache -> větší počet bloků -> větší management overhead
- pravidlo (často ale označované za obsolete)
  - 20% RAM, ale ne víc než 8GB

shared_buffers

- optimální hodnota #2
  - tak akorát pro “aktivní část dat”
  - minimalizace evict-load cyklů
  - minimalizace vyplýtvané paměti (radši page cache, work_mem)
  - Ale jak zjistit?
- iterativní přístup na základě monitoringu
  - konzervativní počáteční hodnota (256MB?)
  - postupně zvětšujeme (2x), sledujeme výkon aplikace
  - tj. latence operací (queries), maintenance, data loads, …
  - zlepšila se latence? pokud ne – snížit (vyžaduje restart)
- reprodukovatelný aplikační benchmark (ne stress test)
  - to samé ale iterace lze udělat daleko rychleji

shared_buffers

- pg_buffercache
  - http://www.postgresql.org/docs/devel/static/pgbuffercache.html
  - extenze dodávaná s PostgreSQL (často v extra -contrib balíku)
  - přidá další systémový pohled (seznam bloků v buffer cache)

```
    CREATE EXTENSION pg_buffercache;

    SELECT
datname,
usagecount,
COUNT(*) AS buffers,
COUNT(CASE WHEN isdirty THEN 1 ELSE NULL END) AS dirty
    FROM pg_buffercache JOIN pg_database d
  ON (reldatabase = d.oid)
    GROUP BY 1, 2
    ORDER BY 1, 2;
```

bgwriter

- background writer (bgwriter)
  - proces pravidelně procházející buffery, aplikuje clock-sweep
  - jakmile “usage count” dosáhne 0, zapíše ho (bez vyhození z cache)
- pg_stat_bgwriter
  - systémový pohled (globální) se statistikami bgwriteru
  - (mimo jiné) počty bloků zapsaných z různých důvodů
  - buffers_alloc – počet bloků načtených do shared buffers
  - buffers_checkpoint – zapsané při checkpointu
  - buffers_clean – zapsané “standardně” bgwriterem
  - buffers_backend – zapsané “backendem” (chceme minimalizovat)

```
SELECT
   now(),
   buffer_checkpoint, buffer_clean, buffer_backend, buffer_alloc
FROM pg_stat_bgwriter;
```

bgwriter (delay / ...)

- alternativní přístup k velikosti shared buffers
  - menší shared buffery + agresivnější zápisy
  - ne vždy lze libovolně zvětšovat shared buffery
- `bgwriter_delay = 200ms`
  - prodleva mezi běhy bgwriter procesu
- `bgwriter_lru_maxpages = 100`
  - maximální počet stránek zapsaných při každém běhu
- `bgwriter_lru_multiplier = 2.0`
  - násobek počtu stránek potřebných během předchozích běhů
  - adaptivní přístup, ale podléhá bgwriter_lru_maxpages
- problém
  - statické hodnoty, nenavázané na velikost shared buffers

zone_reclaim_mode

- NUMA (Non-Uniform Memory Access)
  - What Every Programmer Should Know About Memory (PDF)
  - architektura na strojích s mnoha CPU / velkými objemy RAM
  - RAM rozdělená na části, každá připojená ke konkrétnímu CPU
  - přístupy konkrétního jádra k částem RAM jsou dražší / levnější
  - `numactl --hardware`
- zone_reclaim_mode
  - snaha uvolnit paměť v aktuální zóně (snaha o data locality)
  - https://www.kernel.org/doc/Documentation/sysctl/vm.txt

    For file servers or workloads that benefit from having their data cached, zone_reclaim_mode should be left disabled as the caching effect is likely to be more important than data locality.
  - http://frosty-postgres.blogspot.cz/2012/08/postgresql-numa-and-zone-reclaim-mode.html

work_mem

- limit paměti pro operace
  - default 4MB (velmi konzervativní)
  - jedna query může použít několik operací
  - některé operace nerespektují (Hash Aggregate)
  - ovlivňuje plánování (oceňování dotazů, možnost plánů)
- při překročení se použije temporary file
  - nemusí nutně znamenat zpomalení (může být v page cache)
  - může se použít jiný algoritmus (quick-sort, merge sort)
- optimální hodnota závisí na
  - množství dostupné paměti
  - počtu paralelních dotazů
  - složitosti dotazů (pgbench-like dotazy vs. analytické dotazy)

work_mem

- příklad
  - systému zbývá (RAM – shared_buffers) paměti
  - nechceme použít všechno (vytlačilo by to page cache, OOM atd.)
  - očekáváme že aktivní budou všechna spojení
  - očekáváme že každý dotaz použije 2 * work_mem

```
work_mem = 0.25 * (RAM – shared_buffers) / max_connections / 2;
```

- "spojené nádoby" (méně dotazů -> víc work_mem)
- alternativní postup
  - podívej se na pomalé dotazy,
  - zjisti jestli mají problém s work_mem / kolik by potřebovaly
  - zkontroluj jestli nehrozí OOM a případně změň konfiguraci

work_mem

- work_mem nemusí být nastaveno pro všechny stejně
- lze měnit per session

```
SET work_mem = '1TB';
```

- lze nastavit per uživatele

```
ALTER USER webuser SET work_mem = '8MB';
ALTER USER dwhuser SET work_mem = '128MB';
```

- lze nastavit per databázi

```
ALTER USER webapp SET work_mem = '8MB';
ALTER USER dwh SET work_mem = '128MB';
```

- http://www.postgresql.org/docs/devel/static/sql-alteruser.html
- http://www.postgresql.org/docs/devel/static/sql-alterdatabase.html

maintenance_work_mem

- obdobný význam jako work_mem, ale pro “maintenance” operace
  - CREATE INDEX, REINDEX, VACUUM, REFRESH
- default 64MB – není špatné, ale může se hodit zvýšit
  - např. REINDEX velkých tabulek apod.
- může mít výrazný vliv na operace, ale ne nutně “více je lépe”

```
test=# set maintenance_work_mem = '4MB';
test=# create index test_1_idx on test(i);
CREATE INDEX
Time: 27076,920 ms

test=# set maintenance_work_mem = '64MB';
test=# create index test_1_idx on test(i);
CREATE INDEX
Time: 39468,621 ms
```

max_connections

- default hodnota 100 je často příliš vysoká
  - očekává se že část spojení je neaktivní
  - to často neplatí, backendy si “šlapou po prstech”
  - context switche, lock contention, disk contention, používá se víc RAM, cache line contention (CPU caches), …
  - výsledkem je snížení výkonu / propustnosti, zvýšení latencí, ...
- orientační “tradiční” vzorec

```
((core_count * 2) + effective_spindle_count)
```

- radši použijte nižší hodnotu a connection pool (např. pgbouncer)

https://wiki.postgresql.org/wiki/Number_Of_Database_Connections

effective_cache_size

- default 4GB, ale neovlivňuje přímo žádnou alokaci
- slouží čistě jako “nápověda” při plánování dotazů
  - Jak pravděpodobné je že blok “X” nebudu číst z disku?
  - Jakou část bloků budu muset číst z disku?
- dobrý vzorec

  shared buffers + page cache
- page cache je odhad
  - zbývající RAM bez paměti pro kernel, work_mem, ...
- často se používá
  - 50% paměti jako konzervativní hodnota
  - 75% paměti jako agresivní hodnota
- většinou nemá cenu to detailně tunit

effective_io_concurrency

- Kolik paralelních I/O requestů dokáží disky odbavit?
  - samostatné disky -> 1 nebo víc (díky TCQ, NCQ optimalizacím)
  - RAID pole -> řádově počet disků (spindlů)
  - SSD disky -> dobré zvládají hodně paralelních requestů
- překládá na počet stránek které se mají načíst dopředu
- používá se jenom pro “Bitmap Heap Scan”
  - přeskakuje některé stránky podle bitmapy
  - sequential scan apod. spoléhají na “kernel readahead”
- není součástí plánování (používá se až při exekuci)

effective_io_concurrency

pgbench scale 3000 (45GB database), Intel S3500 SSD

```
EXPLAIN (ANALYZE, BUFFERS)
 SELECT * FROM pgbench_accounts
  WHERE aid BETWEEN 1000 AND 50000000 AND abalance != 0;

                                QUERY PLAN
-------------------------------------------------------------------------
 Bitmap Heap Scan on pgbench_accounts
              (cost=1059541.66..6929604.57 rows=1 width=97)
              (actual time=5040.128..23089.651 rows=1420738 loops=1)
   Recheck Cond: ((aid >= 1000) AND (aid <= 50000000))
   Rows Removed by Index Recheck: 3394823
   Filter: (abalance <> 0)
   Rows Removed by Filter: 48578263
   Buffers: shared hit=3 read=1023980
   ->  Bitmap Index Scan on pgbench_accounts_pkey
              (cost=0.00..1059541.66 rows=50532109 width=0)
              (actual time=5038.707..5038.707 rows=49999001 loops=1)
         Index Cond: ((aid >= 1000) AND (aid <= 50000000))
         Buffers: shared hit=3 read=136611
 Total runtime: 46251.375 ms
```

effective_io_concurrency

http://www.postgresql.org/message-id/CAHyXU0yiVvfQAnR9cyH=HWh1WbLRsioe=mzRJTHwtr=2azsTdQ@mail.gmail.com

```
effective_io_concurrency 1:    46.3 sec, ~ 170 mb/sec
effective_io_concurrency 2:    49.3 sec, ~ 158 mb/sec
effective_io_concurrency 4:    29.1 sec, ~ 291 mb/sec
effective_io_concurrency 8:    23.2 sec, ~ 385 mb/sec
effective_io_concurrency 16:   22.1 sec, ~ 409 mb/sec
effective_io_concurrency 32:   20.7 sec, ~ 447 mb/sec
effective_io_concurrency 64:   20.0 sec, ~ 468 mb/sec
effective_io_concurrency 128:  19.3 sec, ~ 488 mb/sec
effective_io_concurrency 256:  19.2 sec, ~ 494 mb/sec
```

Did not see consistent measurable gains > 256 effective_io_concurrency. Interesting that at setting of '2' (the lowest possible setting with the feature actually working) is pessimal.

readahead

- blockdev --getra /dev/sda
- default 256 sektorů (256 * 512B = 128kB)
- zvýšení většinou zlepší výkon sekvenčního čtení
- dobré hodnoty
  - 2048 (1MB) – standardní disky
  - 16384 (8MB) – střední RAID pole
  - 32768 (16MB) – větší RAID pole
- nemá cenu to dlouho tunit
  - zejména ne na základě syntetického testu (dd, fio, bonnie++, ...)
  - výkon se většinou zpočátku rychle zlepší, pak už roste pomalu

statement_timeout

- optimalizovat rychlost dotazů je fajn, ale ...
- čas od času se objeví “nenažraný dotaz”
  - např. kartézský skoučin produkující 100 trilionů řádek
  - žere spoustu CPU času nebo I/O výkonu (případně obojí)
  - ovlivňuje ostatní aktivitu na systému
- je dobré takové dotazy průběžně zabíjet / fixovat
- statement_timeout
  - limit na maximální délku dotazu (milisekundy)
  - oblivňuje “všechno” (loady, …)
  - stejně jako work_mem apod. jde nastavit per user / db
- alternativa
  - cron skript (umožňuje např. regulární výrazy na dotaz, ...)

temp_file_limit

- alternativní způsob omezení “nenažraných” dotazů
- pokud dotaz generuje moc temporary souborů
- většinou to znamená že běží dlouho
  - nakonec ho zabije statement_timeout
  - do té doby ale bude přetěžovat I/O subsystém
  - z page cache vytlačí všechna zajímavá data
  - nežádoucí interakce s write cache kernelu (dirty_bytes, background_dirty_bytes)

vm / dirty memory

- data se nezapisují přímo na disk, ale do “write cache”
  - kernel to dle svého uvážení zapíše na disk
  - zápis lze vynutit pomocí fsync()
  - konfliktní požadavky na velikost write cache
- chceme velkou write cache
  - kernel má větší volnost v reorganizaci requestů
  - spíše sekvenční zápisy, rewrite bloků -> jediný zápis
- chceme malou write cache
  - rychlejší shutdown (nutnost zapsat všechno)
  - chceme také read cache (read-write ratio 90%)
  - požadavek na hodně paměti (složité dotazy -> nutnost zapsat)

vm / dirty memory

- kernel používá dva prahy / thresholdy

```
dirty_background_bytes <= dirty_bytes
dirty_background_ratio <= dirty_ratio
```

- dirty_background_bytes
  - kernel začne zapisovat na pozadí (pdflush writeback)
  - procesy stále zapisují do write cache
- dirty_bytes
  - kernel stále zapisuje ...
  - ... procesy nemohou zapisovat do write cache (vlastní writeback)

https://www.kernel.org/doc/Documentation/sysctl/vm.txt

http://lwn.net/Articles/28345/

http://www.westnet.com/~gsmith/content/linux-pdflush.htm

vm / dirty memory

- dobré hodnoty (vyladěné pro I/O subsystém)
  - pokud máte řadič s write cache

    ```
    vm.dirty_background_bytes = … write cache …
    vm.dirty_bytes = (8 x dirty_background_bytes)
    ```

  - pokud řadič nemáte, tak radši nižší hodnoty
- /proc/meminfo
  - Dirty — waiting to get written back to the disk (kilobytes)
  - Writeback — actively being written back to the disk (kilobytes)
- nepoužívejte “_ratio” varianty
  - s aktuálními objemy RAM (stovky GB) příliš velké hodnoty
  - 1% z 128GB => víc než 1GB
  - problémy při přidání RAM (najednou jiné thresholdy)

vm / dirty memory

- jak dlouho bude trvat zápis (odhad “záseku”)
  - co když bude velká část zápisů náhodná
  - disková pole, SSD disky – můžete si dovolit vyšší limity
- dobré hodnoty (vyladěné pro I/O subsystém)
  - pokud máte řadič s write cache

    ```
    vm.dirty_background_bytes = (cache řadiče)
    vm.dirty_bytes = (8 x dirty_background_bytes)
    ```

  - pokud řadič nemáte, tak radši nižší hodnoty
- /proc/meminfo
  - Dirty — waiting to get written back to the disk (kilobytes)
  - Writeback — actively being written back to the disk (kilobytes)

vm / dirty memory

- alternativně lze tunit pomocí timeoutů
  - vm.dirty_expire_centisecs – jak dlouho mohou být data v cache před zápisem na disk (default: 30 vteřin)
  - vm.dirty_writeback_centisecs – jak často se pdflush probouzí aby data zapsal na disk (default: 5 vteřin)

io scheduler

- “který scheduler je nejlepší” je tradiční bullshit téma
  - ideální pro pěkné grafy na Phoronixu, v praxi víceméně k ničemu
  - minimální rozdíly, s výjimkou zkonstruovaných “corner case” případů
- říká se že ...
  - **noop** - dobrá volba pro in-memory disky (ramdisk) a tam kde si to zařízení stejně chytře přeorganizuje (nerotační média aka SSDs, RAID pole s řadičem a BBWC)
  - **deadline** - lehký jednoduchý scheduler snažící se o rovnoměrné latence
  - **anticipatory** – koncepčně podobný deadline, se složitější heuristikou která často zlepšuje výkon (a někdy naopak zhoršuje)
  - **cfq** – se snaží o férové rozdělení I/O kapacity v rámci systému
- ale **cfq** je “default” scheduler, a např. “ionice” funguje jenom v něm

wal_level

- které informace se musí zapisovat do Write Ahead Logu
- několik úrovní, postupně přidávajících detaily
- `minimal`
  - lokální recovery (crash, immediate shutdown)
  - může přeskočit WAL pro některé příkazy (CREATE TABLE AS, CREATE INDEX, CLUSTER, COPY do tabulky vytvořené ve stejné transakci)
- `archive`
  - WAL archivace (log-file shipping replikace, warm_standby)
- `hot_standby`
  - read-only standby
- `logical`
  - možnost logické replikace (interpretuje WAL log)

wal_level

- `minimal`
  - může ušetřit zápis WAL pro “ignorované” operace
  - vesměs málo časté maintenance operace (CREATE INDEX, CLUSTER)
  - nebo nepříliš používané operace (CREATE TABLE + COPY, CTAS)
  - irelevantní pokud potřebujete lepší recovery
  - možná pro iniciální load dat
- `archive / hot_standby / logical`
  - minimální rozdíly mezi volbami (objem, CPU overhead, ...)

wal_log_hints

- MVCC
  - zpřístupnění více verzí řádek paralelně běžícím transakcím
  - moderní alternativa k zamykání (řádek, tabulek, …)
  - u každého řádku jsou ID dvou transakcí – INSERT / DELETE
  - nutná kontrola zda daná transakce skončila (commit / rollback)
  - náročné na CPU, takže se výsledek cachuje pomocí “hint bitu”
  - původně se nelogovalo do WAL (kontrola se zopakuje)
  - problém po recovery / na replikách (hint bity nenastaveny, všechno se musí zkontrolovat znovu proti commit logu)
- odkazy
  - http://en.wikipedia.org/wiki/Multiversion_concurrency_control
  - http://www.postgresql.org/docs/current/static/mvcc-intro.html
  - http://momjian.us/main/writings/pgsql/internalpics.pdf
  - http://momjian.us/main/writings/pgsql/mvcc.pdf

wal_buffers

- od 9.1 víceméně obsolete
  - nastavuje se automaticky na 1/32 shared_buffers
  - maximálně 16MB (manuálně lze nastavit víc)
  - není důvod na to víc šahat
- na starších verzích používejte stejnou logiku
  - těžko vymyslíte něco lepšího

checkpoint_segments

- COMMIT
  - zápis do transakčního logu (WAL) + fsync
  - sekvenční povaha zápisů
  - úprava dat v shared bufferech (bez zápisu na disk)
- WAL
  - rozdělený na 16MB segmenty
  - omezený počet, recyklace
- CHECKPOINT
  - zápis změn ze shared buffers do datových souborů
  - náhodná povaha zápisů
  - nutný při recyklaci nebo timeoutu (checkpoint_timeout)

checkpoint_segments

- checkpoint_segments = 3 (default)
  - 48MB změn, v praxi velmi nízká hodnota
  - konzervativní (minimální nároky na diskový prostor)
- praktičtější hodnoty
  - 32 (512MB), 64 (1GB), ...
  - souvisí s velikostí write cache na řadiči
- Pozor!
  - čím vyšší hodnota, tím déle může trvat recovery
  - musí se přehrát všechny změny od posledního checkpointu

checkpoint_timeout apod.

- checkpoint_timeout
  - maximální vzdálenost mezi checkpointy
  - default 5 minut (dost agresivní), maximum 1 hodina
  - v postatě horní limit na recovery time
  - recovery je většinou rychlejší (jenom samotné zápisy)
- checkpoint_completion_target
  - až do 8.2 problém s I/O při checkpointu (write + fsync)
  - completion_target rozkládá zápisy a fsync v čase
  - další checkpoint skončil než začne následující (0.5 – 50%)
  - funguje s “timed” i “xlog” checkpointy

checkpoint tuning

- pg_stat_bgwriter

```
SELECT checkpoints_timed, checkpoints_req
  FROM pg_stat_bgwriter;

 checkpoints_timed | checkpoints_req
-------------------+-----------------
               201 |             159
```

- obecně většina checkpointů by měla být “timed”
- cílem je minimalizovat checkpoints_req

synchronous_commit

- má se čekat na dokončení commitu?
  - “durability tuning” dlouho před NoSQL hype
  - stále plně transakční / ACID
- až do 9.0 jenom on / off
- 9.1 přidala synchronní replikaci – daleko víc možností
  - on (default) – čekej na commit
  - remote_write – čekej i na zápis do WAL na replice (9.1)
  - local – nečekej na repliku, stačí lokální WAL (9.1)
  - off – nečekej ani na lokální WAL
- jde nastavovat “per transakce”
  - důležité “on”, méně důležité “local”

http://www.postgresql.org/docs/9.4/static/runtime-config-wal.html

commit_delay / siblings

- způsob jak “obejít” IOPS limit disků
  - 7.2k disk má limit ~100 IOPS, 15k ~250 IOPS, ...
  - víceméně limit pro “fsync rate” (modulo TCQ/NCQ apod.)
- co kdybychom transakce necommitovali po jedné?
  - chvilku počkáme a “nahromaděné” commitneme najednou
- potřebujeme aby
  - běželo několik transakcí
  - skončily skoro ve stejnou chvíli
- parametry
  - commit_siblings – počet transakcí které musí běžet
  - commit_delay – jak dlouho čekat (1/IOPS)

commit_delay / siblings

- funguje jenom pro krátké transakce (řádově 1/IOPS)
- obsolete od 9.2 – implementován “group commit”
  - lepší (chytřejší, automaticky, ...)
- příklad v praxi
  - http://www.linux.cz/pipermail/linux/2011-December/270072.html
  - dSpam ukládající data do PostgreSQL
  - několik INSERT/UPDATE procesů + autocommit

	medián (s)	pct90 (s)
commit_delay=0	7.66	25.32
commit_delay=1500	2	4.86
synchronous_commit=off	0.42	0.56

autovacuum options

- autovacuum_work_mem = -1 (maintenance_work_mem)
- autovacuum_max_workers = 3
- autovacuum_naptime = 1min
- autovacuum_vacuum_threshold = 50
- autovacuum_analyze_threshold = 50
- autovacuum_vacuum_scale_factor = 0.2
- autovacuum_analyze_scale_factor = 0.1
- autovacuum_freeze_max_age = 200000000
- autovacuum_multixact_freeze_max_age = 400000000
- autovacuum_vacuum_cost_delay = 20ms
- autovacuum_vacuum_cost_limit = -1 (vacuum_cost_limit=200)
- vacuum_cost_page_hit = 1
- vacuum_cost_page_miss = 10
- vacuum_cost_page_dirty = 20

autovacuum = off

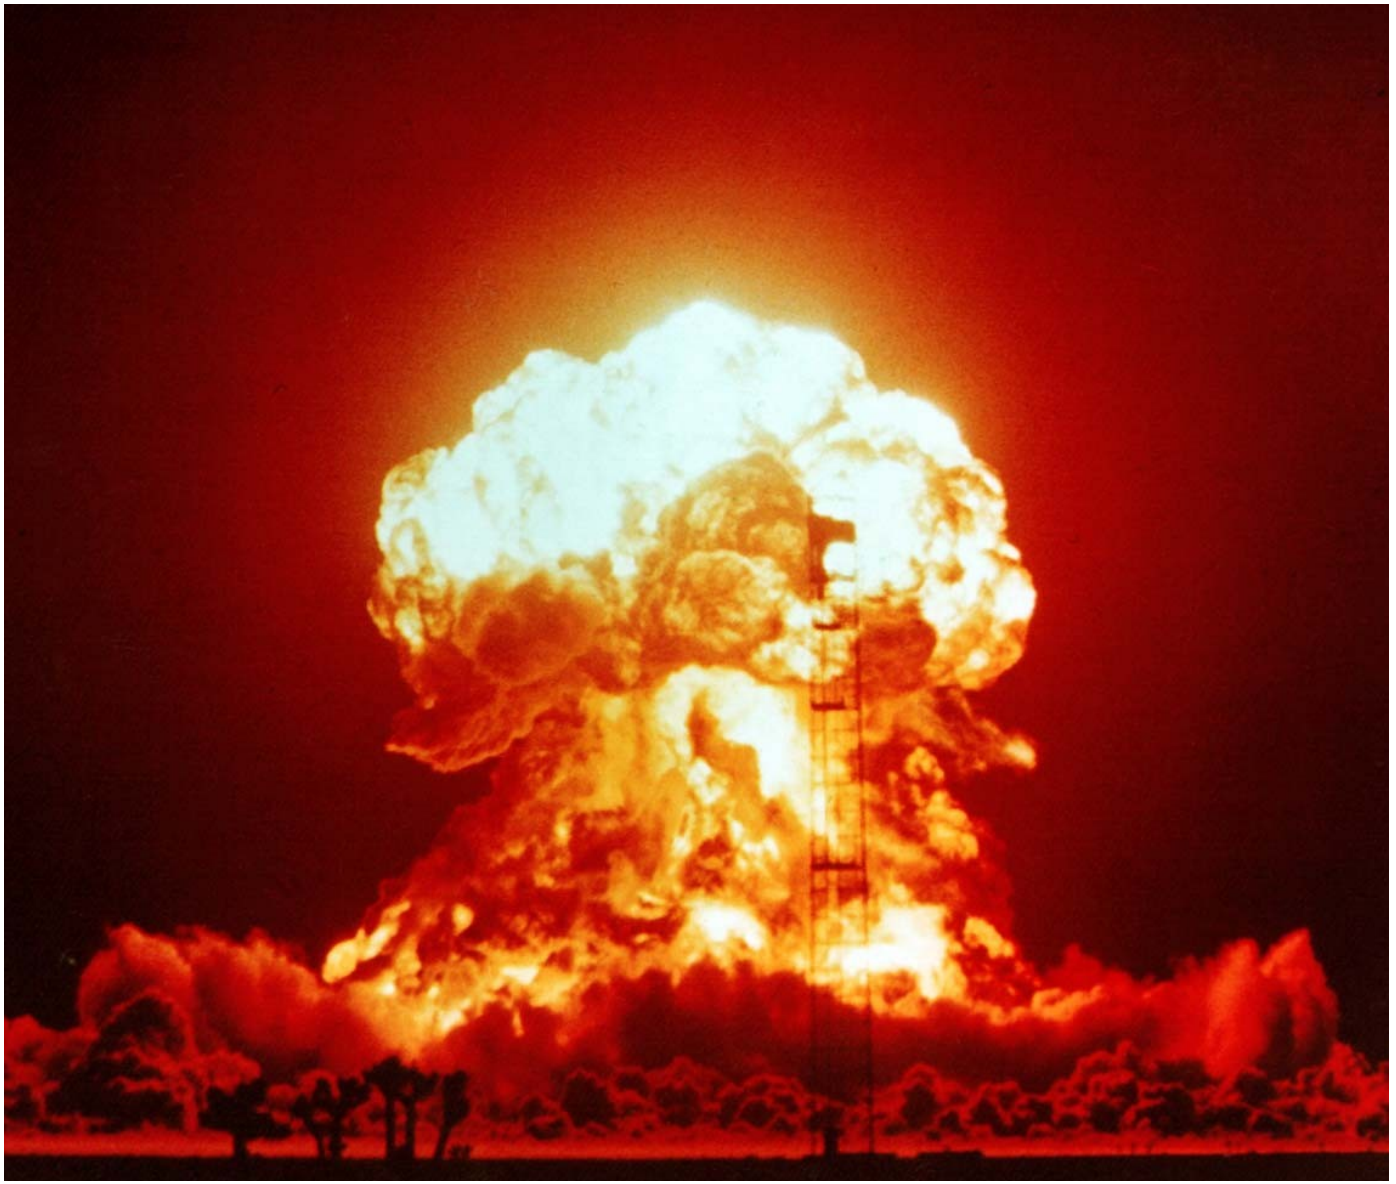

http://en.wikipedia.org/wiki/Nuclear_explosion

autovacuum thresholds

- `autovacuum_naptime = 1min`
  - prodleva mezi běhy “autovacuum launcher” procesu
  - v rámci běhu se spustí autovacuum na všech DB
  - interval mezi autovacuum procesy (1 minuta / počet DB)
  - jinak – interval mezi běhy autovacuum na konkrétní DB
- `autovacuum_vacuum_threshold = 50`
- `autovacuum_analyze_threshold = 50`
- `autovacuum_vacuum_scale_factor = 0.2`
- `autovacuum_analyze_scale_factor = 0.1`
  - parametry určující které tabulky se mají čistit / analyzovat

```
změněných_řádek > (threshold + celkem_řádek * scale_factor)
```

autovacuum thresholds

- `autovacuum_vacuum_cost_delay = 20ms`
- `autovacuum_vacuum_cost_limit = -1 (vacuum_cost_limit=200)`
- `vacuum_cost_page_hit = 1`
- `vacuum_cost_page_miss = 10`
- `vacuum_cost_page_dirty = 20`
- parametry určující agresivitu autovacuum operace
  - maximálně 200 stránek za kolo / 10000 za vteřinu (jen buffer hits)
  - pokud musí načíst do shared buffers tak 20 / 1000
  - pokud skutečně vyčistí (tj. označí jako dirty) tak 10 / 500
- problém pokud není dostatečně agresivní
  - bloat (nečistí se smazané řádky) – pomalejší dotazy, diskový prostor
  - wraparound (32-bit transaction IDs)

random_page_cost

- při plánování se používá zjednodušený model “ceny” plánu
- pět “cost” proměnných
  - seq_page_cost = 1
  - random_page_cost = 4
  - cpu_tuple_cost = 0.01
  - cpu_index_tuple_cost = 0.005
  - cpu_operator_cost = 0.0025
- změna hodnot se velmi obtížně se ověřuje
  - jednomu dotazu to pomůže, druhému ublíží :-(
- asi jediné co se obecně vyplatí tunit je random_page_cost
  - na SSD, velkých RAID polích zkuste snížit na 2, možná 1.5

logging & monitoring

- důležité volby
  - `log_line_prefix (string)`
  - `log_min_duration_statement (integer)`
  - `log_checkpoints (boolean)`
  - `log_temp_files (integer)`

- zajímavé nástroje
  - http://pgfouine.projects.pgfoundry.org/
  - http://dalibo.github.io/pgbadger/

auto_explain

- `auto_explain.log_min_duration (integer)`
- `auto_explain.log_analyze (boolean)`
- `auto_explain.log_buffers (boolean)`
- `auto_explain.log_timing (boolean)`
- `auto_explain.log_triggers (boolean)`
- `auto_explain.log_verbose (boolean)`
- `auto_explain.log_format (enum)`
- … další volby …

http://www.postgresql.org/docs/devel/static/auto-explain.html

pg_stat_statements

- userid
- dbid
- queryid
- query
- calls
- total_time
- rows
- shared_blks_hit
- shared_blks_read
- shared_blks_dirtied
- shared_blks_written
- local_blks_hit
- local_blks_read
- local_blks_dirtied
- local_blks_written
- temp_blks_read
- temp_blks_written
- blk_read_time
- blk_write_time

metodika

- mějte jasnou představu o výkonu systému
  - ideálně výsledky sady měření která můžete rychle zopakovat
  - ověření že HW je v pořádku apod. (umřel disk, baterka na řadiči)
  - slouží jako baseline pro ostatní (např. na mailinglistu)
- mějte monitoring
  - spousta věcí se dá zjistit pohledem na grafy (náhlé změny apod.)
  - může vás to rovnou navést na zdroj problému nebo symptomy
  - může vám to říct kdy k problému došlo, jestli rostl pomalu nebo se to stalo náhle, apod.
- zkuste rychle vyřešit “seshora” (fix SQL dotazu, …)
  - může se jednat o “klasický problém” (chybějící index, ...)
- pokud nejde, postupujte systematicky odspodu (neskákejte)
  - hardware, OS, databáze, aplikace, ...

souborové systémy

- ext3
  - ne, zejména kvůli problémům při fsync (všechno)
- ext4, XFS
  - cca stejný výkon, berte to co je “default” vaší distribuce
  - mount options: noatime, barrier=(0|1), discard (SSD, ext4 i xfs)
  - XFS tuning: allocsize, agcount/agsize (mkfs)
- ZFS / BTRFS
  - primárním motivem není vyšší výkon, ale jiné vlastnosti (odolnost na commodity hw, snapshoty, komprese, ...)
  - špatný výkon na random workloadech (zejména r-w)
  - dobrý výkon na sekvenčních (lepší než XFS / EXT4, ...)
  - http://www.citusdata.com/blog/64-zfs-compression

Durability tuning

bezpečné

- synchronous_commit = off
- checkpoint_segments = vysoké číslo
- unlogged tables (při pádu DB zmizí, nereplikují se)

nebezpečné

- fsync = off
- full_page_writes = off
- unlogged tables (při pádu DB zmizí, nereplikují se)

http://www.postgresql.org/docs/9.4/static/non-durability.html

Load data (iniciální)

- vypněte AUTOCOMMIT (BEGIN/END)
- použijte COPY namísto INSERT
- odstraňte INDEXy a FK (cizí klíče)
- zvyšte maintenance_work_mem a checkpoint_segments
- vypněte WAL archivaci a streaming replikaci
  - `wal_level=minimal, archive_mode=off, max_wal_senders=0`
- po loadu proveďte ANALYZE
- pokud používáte pg_dump, zkuste použít paralelní mód
  - `pg_dump -j N ... / pg_restore -j N ...`

http://www.postgresql.org/docs/9.4/static/populate.html

Disk layout

- WAL
  - sekvenční zápisy
  - téměř se nečte (s výjimkou recovery)
- data files
  - častý náhodný přístup (zápis i čtení)
  - ...